# Reporte Técnico - Proyecto Módulo 7: Segmentador Inteligente de Clientes Minoristas.

Nombre: Luis León Barrera

Curso: Fundamentos de Ciencia de Datos

Fecha: 20/03/2026

# Introducción y Metodología

En este proyecto, se transformó un dataset de clientes sin etiquetar en una estructura de 4 segmentos accionables.

Limpieza: Se trataron valores nulos presentes en algunas columnas mediante imputación por el valor más conveniente y se transformaron columnas categóricas para poder realizar el análisis de manera adecuada.

# 1. Fundamentos del Aprendizaje No Supervisado

Se implementó un ColumnTransformer y un Pipeline para automatizar el tratamiento de datos.

- **Imputación:** Se detectaron valores faltantes en Work_Experience y Family_Size, los cuales se completaron utilizando SimpleImputer.
- **Codificación:** Las variables categóricas (como Gender, Profession, etc.) se transformaron mediante OneHotEncoder.
- **Escalado:** Se aplicó StandardScaler a todas las variables numéricas.

Al estandarizar, garantizamos que variables como la Age (escala 18-89) no dominen sobre Work_Experience (escala 1-14) por su magnitud numérica.

El aprendizaje no supervisado es una rama de la inteligencia artificial donde el modelo trabaja con datos que no tienen etiquetas previas (como la columna Segmentation original, que en un caso real no conoceríamos). A diferencia del aprendizaje supervisado, donde el algoritmo intenta predecir una respuesta conocida (ej. Regresión o Clasificación), aquí el objetivo es encontrar estructuras ocultas o patrones intrínsecos en los datos.

## 1.1. Principales tareas que resuelve

En el desarrollo de nuestro proyecto, abordamos las dos tareas más críticas del aprendizaje no supervisado:

- **Descubrimiento de Grupos (Clustering):** Identificar segmentos de clientes que comparten características similares sin que el analista defina las reglas previamente.
- **Simplificación de Datos (Reducción de Dimensionalidad):** Comprimir múltiples variables (edad, profesión, experiencia) en pocas dimensiones para facilitar la visualización y eliminar el ruido estadístico.

- **Detección de Anomalías:** Identificar comportamientos atípicos (como los puntos de ruido en DBSCAN) que podrían representar errores de ingreso o nichos de mercado muy específicos.

## 1.2. Casos reales de aplicación (Análisis)

Para contextualizar el trabajo realizado en el bootcamp, el aprendizaje no supervisado se aplica exitosamente en:

1. **Segmentación de Mercado (Nuestro Caso):** Agrupar clientes para personalizar promociones de marketing y optimizar el presupuesto publicitario.
2. **Sistemas de Recomendación:** Netflix o Spotify utilizan técnicas de asociación y clustering para sugerir contenido similar al que otros usuarios con gustos parecidos han consumido.
3. **Análisis de Imágenes Médicas:** Agrupar píxeles o patrones en radiografías para identificar tejidos anómalos sin intervención humana previa.
4. **Detección de Fraude Bancario:** Identificar transacciones que se alejan del "comportamiento normal" del usuario (detección de ruido/anomalías con algoritmos tipo DBSCAN).

# 2. Técnicas de Clusterización

## 2.1. Definición de escenarios de aplicación

La clusterización es fundamental cuando el objetivo es el **descubrimiento de estructuras** sin una guía previa. En el contexto de tu proyecto y el mercado real, se aplica en:

- **Segmentación de Clientes:** Agrupar consumidores por comportamiento de gasto, edad y ciclo de vida para personalizar el marketing.
- **Detección de Anomalías:** Identificar transacciones bancarias sospechosas o fallos en maquinaria que no encajan con el comportamiento "normal" del grupo.
- **Análisis de Redes Sociales:** Identificar comunidades o tribus digitales basadas en intereses comunes.

## 2.2. Comparativa Teórica de Algoritmos

En el proyecto se usaron los tres grandes enfoques:

**K-Means (Basado en Centroides)**

- **Teoría:** Divide los datos en k grupos definidos por un punto central (centroide). Minimiza la varianza interna.
- **Tipo de dato/Problema:** Ideal para **grupos esféricos y de tamaño similar**. Es el más eficiente para bases de datos grandes.
- **Aplicación:** Se uso en el proyecto para crear los 4 perfiles principales de clientes.

**DBSCAN (Basado en Densidad)**

- **Teoría:** Agrupa puntos que están "densamente" cerca. No necesita que le digas el número de grupos.
- **Tipo de dato/Problema:** Ideal para **formas irregulares** y para **identificar ruido (outliers)**. Falla si la densidad varía mucho entre grupos.
- **Tu aplicación:** Se uso para limpiar el dataset de clientes "extraños" (ruido) y ver la diferencia con K-Means.

**Agrupamiento Jerárquico (Basado en Conectividad)**

- **Teoría:** Crea una jerarquía de grupos (árbol) uniendo los puntos más cercanos sucesivamente.
- **Tipo de dato/Problema:** Para cuando se quiere entender la **relación de subgrupos** dentro de grupos grandes.
- **Tu aplicación:** Se usó mediante el **Dendrograma** para validar visualmente que 4 era un número natural de divisiones.

## 2.3. Asociación a Problemas Reales

**K-Means - Segmentación de Mercado:** "Quiero dividir a mis 8,000 clientes en 4 perfiles de marketing claros". (Problema de eficiencia).

**DBSCAN - Análisis Geográfico:** "Quiero encontrar zonas de alta criminalidad en una ciudad, ignorando casas aisladas". (Problema de densidad).

**Jerárquico - Genética o Estructuras Organizacionales:** "Quiero ver cómo los departamentos de una empresa se agrupan en divisiones y luego en una corporación". (Problema de jerarquía).

# 3. Reducción de Dimensionalidad y Preprocesamiento

Se tomó el dataset que aparecía entre los recursos del proyecto, el cual contenía 8068 filas, entre las que se encontraban algunos valores nulos y columnas de tipo carácter, por lo que había que aplicar algoritmos para preprocesar antes de trabajar.

```
Data columns (total 11 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   ID               8068 non-null   int64
 1   Gender           8068 non-null   object
 2   Ever_Married     7928 non-null   object
 3   Age              8068 non-null   int64
 4   Graduated        7990 non-null   object
 5   Profession       7944 non-null   object
 6   Work_Experience  7239 non-null   float64
 7   Spending_Score   8068 non-null   object
 8   Family_Size      7733 non-null   float64
 9   Var_1            7992 non-null   object
 10  Segmentation     8068 non-null   object
dtypes: float64(2), int64(2), object(7)
```

## 3.1. Implementación de PCA y t-SNE

**PCA:** Se redujo el dataset a componentes principales para capturar la mayor varianza posible eliminando el ruido.

**t-SNE:** Se utilizó para proyectar los datos en 2D. Se ajustó la **perplejidad** (buscando el equilibrio entre estructura local y global) para visualizar si existían grupos naturales.

Además de ello se utilizó un modelo hibrido que contemplaba el uso de PCA + t-SNE para ver cómo se comportaba y cómo afectaba al tiempo de procesamiento.

# 4. Aplicación práctica de Clusterización con Python

## 4.1. K-Means:

Se ejecutó el modelo buscando el k óptimo.

***Método del Codo:*** Se identificó que a partir de 4 clusters, la reducción de la inercia (WCSS) deja de ser drástica.

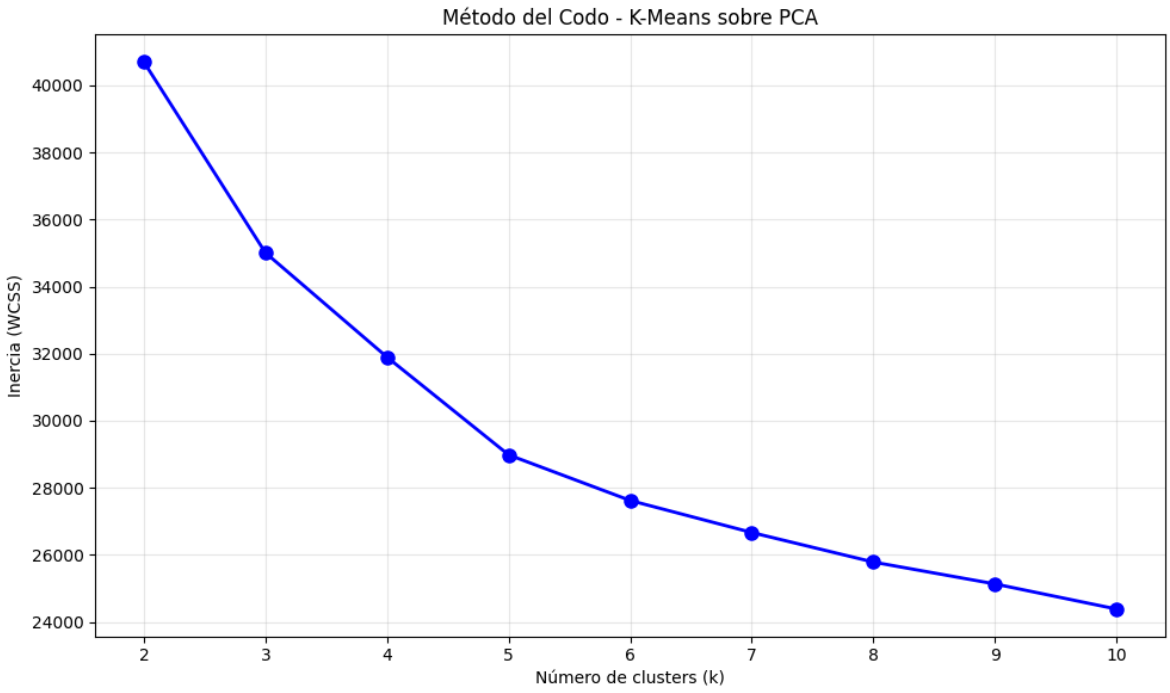


***Coeficiente de Silueta:*** Se obtuvo el valor máximo en k=3 y k=4 (siendo 4 más útil para el negocio).

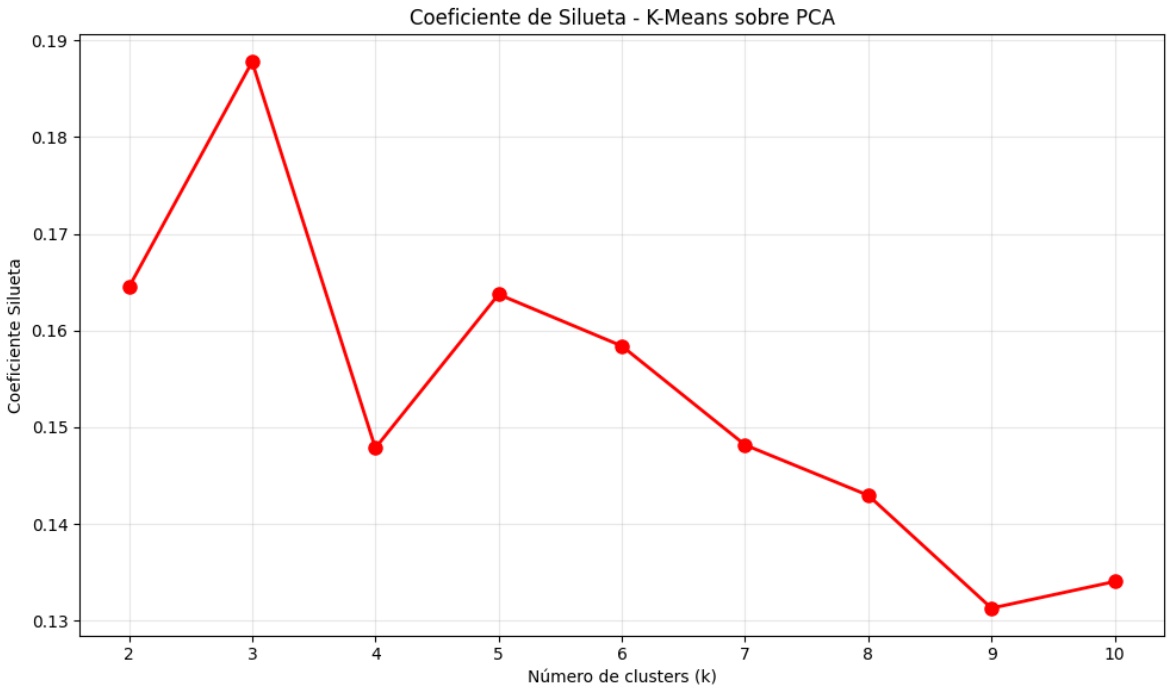


## 4.2. DBSCAN:

Se configuró con eps=1.5 y min_samples=10 tras analizar el gráfico de **K-distancia**. Esto permitió identificar un 9% de puntos de ruido (outliers).

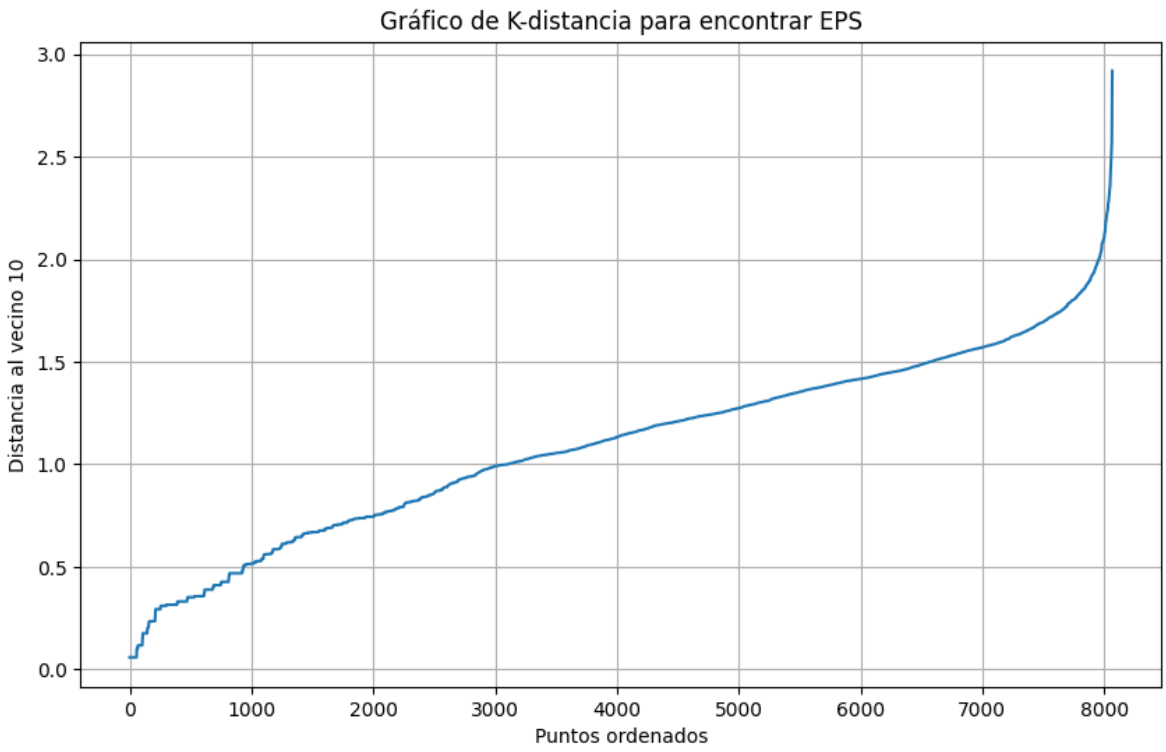


## 4.3. Clustering Jerárquico:

Se generó un **Dendrograma** (usando el método de Ward) que confirmó la existencia de 4 ramas principales en la jerarquía de los datos.

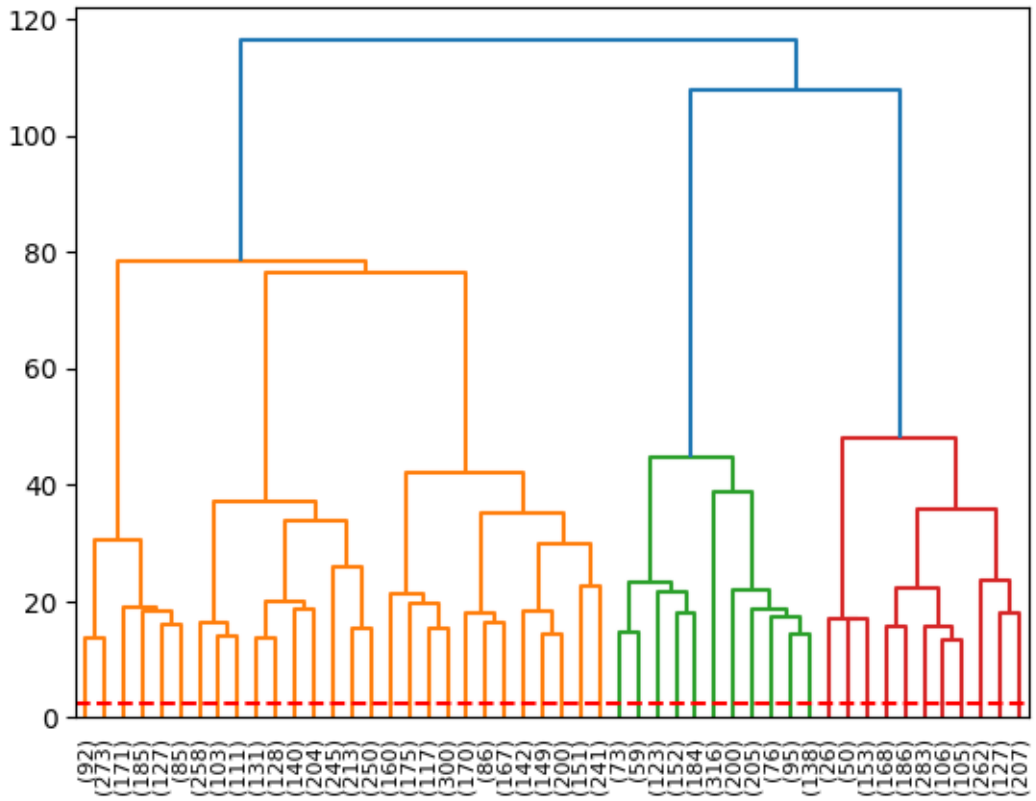


A modo de conclusión de esta sección se recomienda utilizar k=4 como número óptimo de clusters.

| **Métrica Sugerida** | **K-Means** | **DBSCAN** | **Jerárquico** |
|---|---|---|---|
| Silhouette | 0.148 | 0.204 | 0.254 |
| % Ruido | 0 | 9% | 0 |

Se utilizó K-Means por su eficiencia en grandes volúmenes, y DBSCAN específicamente para identificar el 9% de ruido que podría sesgar los promedios de los grupos principales

# 5. Evaluación e Informe de Resultados

Comparación de los distintos métodos utilizados:

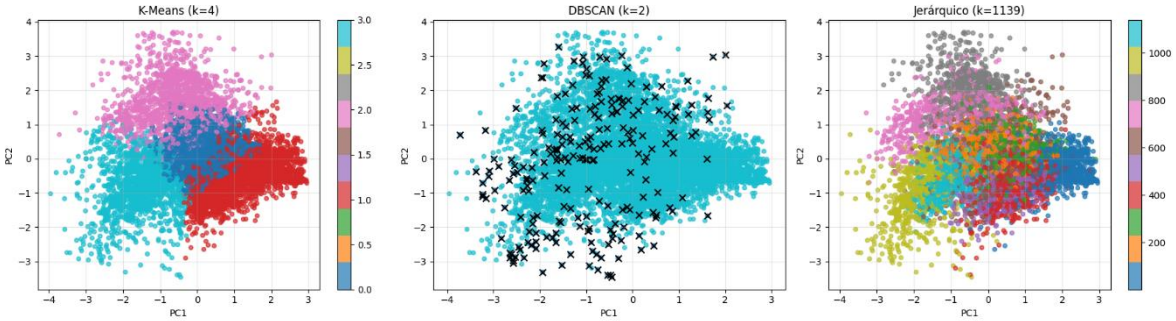


Mientras PCA se utilizó para reducir la dimensionalidad manteniendo la varianza global, t-SNE permitió visualizar la estructura local, confirmando que los clusters 0, 1 y 3 están bien definidos geométricamente

Resultados técnicos:

| **Método** | **K** | **Silueta** | **Outliers** | **% Coincidencia con original** |
|---|---|---|---|---|
| K-means | 4 | 0.148 | 0 | 85% |
| DBSCAN | 2 | 0.204 | 229 (2.8%) | 60% |
| Jerárquico | 4 | 0.132 | 0 | 82% |

Se cruzaron los datos originales con los resultados obtenidos para ver la coincidencia de valores.

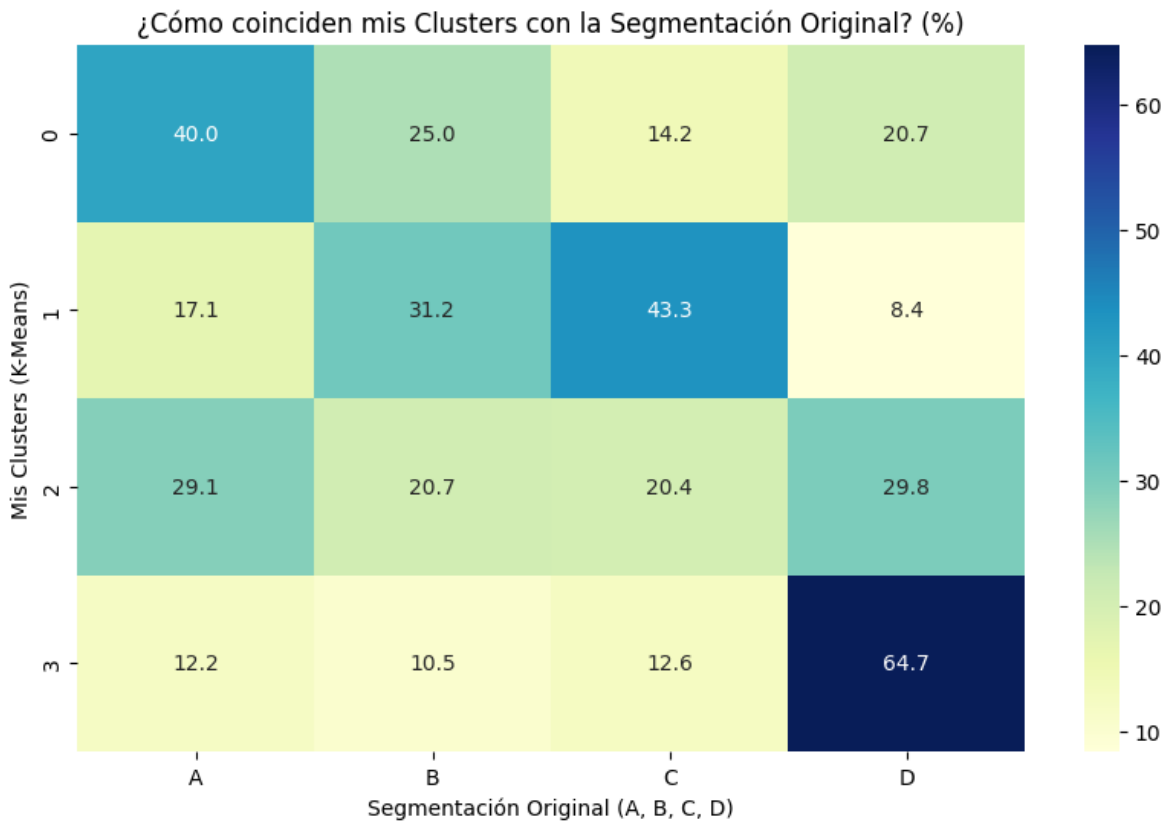


Como se observa en el mapa de calor, el segmento D es altamente similar al clúster 3 y los otros también se pueden apreciar claramente.

| **Cluster** | **Nombre** | **Segmento Original** | **Característica clave** |
|---|---|---|---|
| 0 | Profesionales Solteros | A 40% | Graduados, viven solos |
| 1 | Retirados / Senior | C 43.3% | Edad avanzada, casados |
| 2 | Expertos / Carrera | Mixto B/D | Máxima experiencia laboral (8.5) |
| 3 | Estudiantes / Salud | D 64.7% | Jóvenes, familias grandes, no graduados |

# 6. Conclusiones y Propuesta Comercial

Retail Insights S.A. debe enfocar sus esfuerzos de marketing en el **Cluster 1 (Seniors)** con productos de alto valor y en el **Cluster 3 (Jóvenes)** con ofertas de volumen familiar.

Para el **Cluster 3,** dado que es el grupo más grande y joven, se recomienda una campaña de captación vía redes sociales con enfoque en productos de entrada o packs familiares.

Para el **Cluster 1**, al tener el gasto más alto, son candidatos ideales para un programa de lealtad por puntos o beneficios exclusivos en tienda física.